



Predicción de Lluvia en Australia

Angelo Cancino, Felipe Ruiz
John Rios Griego, Mayo 2024

Introducción

Australia es uno de los países más extensos del mundo y presenta una gran diversidad climática y geográfica. A pesar de ser el continente más seco y llano del planeta, este cuenta con regiones de clima tropical, desértico, semiárido y templado-continental. Las precipitaciones varían considerablemente en términos de distribución, esto debido a que estas precipitaciones son escasas en el interior y más abundantes en las zonas costeras.

Para el siguiente estudio se propone predecir los patrones de lluvia en Australia, y es para esto que se dispone de un dataset que recoge observaciones meteorológicas diarias de diversas ubicaciones en Australia. Estos datos han sido obtenidos de la Oficina de Meteorología de la Commonwealth de Australia.


Modelo de Regresión

Para la predicción de cuánta lluvia cae en milímetros en Australia se decidió realizar un modelo de regresión lineal múltiple.

La elección de este modelo se basa en la naturaleza del conjunto de datos y el problema a resolver. En nuestro caso estamos intentando predecir la cantidad de lluvia en milímetros, lo cual es una variable continua, esto a partir de variables independientes como lo son MinTemp, MaxTemp, Sol, Humedad, etc.

Primero se realizó la limpieza del dataset, para lo cual comenzamos buscando si existen datos NA dentro de las columnas.

```
```{r}
#ver la cantidad de na
porcentaje=inspect_na(lluvia)
show_plot(porcentaje)
````
```



Luego se cambiaron los valores de tipo char a tipo numérico para poder ser procesadas por la red neuronal.

```
```{r}
#transformar una variable cuantitativa a numerica

lluvia$RainToday<- ifelse(lluvia$RainToday == "Yes", 1, 0)
lluvia$RainTomorrow<- ifelse(lluvia$RainTomorrow == "Yes", 1, 0)

lluvia$WindGustDir <- ifelse(lluvia$WindGustDir == "W", 1, ifelse(lluvia$WindGustDir == "SE", 2, ifelse(lluvia$WindGustDir == "E", 3, ifelse(lluvia$WindGustDir == "N", 4, ifelse(lluvia$WindGustDir == "SSE", 5, ifelse(lluvia$WindGustDir == "S", 6, ifelse(lluvia$WindGustDir == "WSW", 7, ifelse(lluvia$WindGustDir == "SW", 8, ifelse(lluvia$WindGustDir == "SSW", 9, ifelse(lluvia$WindGustDir == "WNW", 10, ifelse(lluvia$WindGustDir == "NW", 11, ifelse(lluvia$WindGustDir == "ENE", 12, ifelse(lluvia$WindGustDir == "ESE", 13, ifelse(lluvia$WindGustDir == "NE", 14, ifelse(lluvia$WindGustDir == "NNW", 15, 16))))))))))))))

lluvia$WindDir9am <- ifelse(lluvia$WindDir9am == "W", 1, ifelse(lluvia$WindDir9am == "SE", 2, ifelse(lluvia$WindDir9am == "E", 3, ifelse(lluvia$WindDir9am == "N", 4, ifelse(lluvia$WindDir9am == "SSE", 5, ifelse(lluvia$WindDir9am == "S", 6, ifelse(lluvia$WindDir9am == "WSW", 7, ifelse(lluvia$WindDir9am == "SW", 8, ifelse(lluvia$WindDir9am == "SSW", 9, ifelse(lluvia$WindDir9am == "WNW", 10, ifelse(lluvia$WindDir9am == "NW", 11, ifelse(lluvia$WindDir9am == "ENE", 12, ifelse(lluvia$WindDir9am == "ESE", 13, ifelse(lluvia$WindDir9am == "NE", 14, ifelse(lluvia$WindDir9am == "NNW", 15, 16))))))))))))))

lluvia$WindDir3pm <- ifelse(lluvia$WindDir3pm == "W", 1, ifelse(lluvia$WindDir3pm == "SE", 2, ifelse(lluvia$WindDir3pm == "E", 3, ifelse(lluvia$WindDir3pm == "N", 4, ifelse(lluvia$WindDir3pm == "SSE", 5, ifelse(lluvia$WindDir3pm == "S", 6, ifelse(lluvia$WindDir3pm == "WSW", 7, ifelse(lluvia$WindDir3pm == "SW", 8, ifelse(lluvia$WindDir3pm == "SSW", 9, ifelse(lluvia$WindDir3pm == "WNW", 10, ifelse(lluvia$WindDir3pm == "NW", 11, ifelse(lluvia$WindDir3pm == "ENE", 12, ifelse(lluvia$WindDir3pm == "ESE", 13, ifelse(lluvia$WindDir3pm == "NE", 14, ifelse(lluvia$WindDir3pm == "NNW", 15, 16))))))))))))))

```
```
#lluvia$Windgustdir[is.na(lluvia$WindGustDir)] <- 0

summary(lluvia)
head(lluvia)
```



Date	Location	MinTemp	MaxTemp	Rainfall	Evaporation	Sunshine	WindGustDir	WindGustSpeed	WindDir9am
2008-12-01	Albury	13.4	22.9	0.6	NA	NA	1	44	1
2008-12-02	Albury	7.4	25.1	0.0	NA	NA	10	44	15
2008-12-03	Albury	12.9	25.7	0.0	NA	NA	7	46	1
2008-12-04	Albury	9.2	28.0	0.0	NA	NA	14	24	2
2008-12-05	Albury	17.5	32.3	1.0	NA	NA	1	41	12
2008-12-06	Albury	14.6	29.7	0.2	NA	NA	10	56	1



6 rows | 1-10 of 24 columns


```

y para concluir con el proceso de limpieza se realiza un .omit a los valores NA.

```
```{r}
#data sin na

lluvia_sin_na<-na.omit(lluvia)
head(lluvia_sin_na)

summary(lluvia_sin_na)


```


Date	Location	MinTemp	MaxTemp	Rainfall	Evaporation	Sunshine	windgustdir
Min. : 2007-11-01	Length:56420	Min. :-6.70	Min. : 4.10	Min. : 0.00	Min. : 0.000	Min. : 0.000	Min. : 1.000
1st Qu.: 2010-07-19	Class :character	1st Qu.: 8.60	1st Qu.: 18.70	1st Qu.: 0.00	1st Qu.: 2.800	1st Qu.: 5.000	1st Qu.: 4.000
Median : 2012-07-28	Mode :character	Median :13.20	Median :23.90	Median : 0.00	Median : 5.000	Median : 8.600	Median : 8.000
Mean : 2012-09-17		Mean :13.46	Mean :24.22	Mean : 2.13	Mean : 5.503	Mean : 7.736	Mean : 7.868
3rd Qu.: 2014-10-10		3rd Qu.:18.40	3rd Qu.:29.70	3rd Qu.: 0.60	3rd Qu.: 7.400	3rd Qu.:10.700	3rd Qu.:12.000
Max. : 2017-06-25		Max. :31.40	Max. :48.10	Max. :206.20	Max. :81.200	Max. :14.500	Max. :16.000
windgustspeed	windDir9am	windDir3pm	windspeed9am	windspeed3pm	humidity9am	humidity3pm	pressure9am
Min. : 9.00	Min. : 1.000	Length:56420	Min. : 2.00	Min. : 2.00	Min. : 0.00	Min. : 0.0	Min. : 980.5
1st Qu.: 31.00	1st Qu.: 4.000	Class :character	1st Qu.: 9.00	1st Qu.:13.00	1st Qu.: 55.00	1st Qu.: 35.0	1st Qu.:1012.7
Median : 39.00	Median : 8.000	Mode :character	Median :15.00	Median :19.00	Median : 67.00	Median : 50.0	Median :1017.2
Mean : 40.88	Mean : 8.083		Mean :15.67	Mean :19.79	Mean : 65.87	Mean : 49.6	Mean :1017.2
3rd Qu.: 48.00	3rd Qu.:12.000		3rd Qu.:20.00	3rd Qu.:26.00	3rd Qu.: 79.00	3rd Qu.: 63.0	3rd Qu.:1021.8
Max. :124.00	Max. :16.000		Max. :67.00	Max. :76.00	Max. :100.00	Max. :100.0	Max. :1040.4
pressure3pm	Cloud9am	Cloud3pm	Temp9am	Temp3pm	RainToday	RISK_MM	RainTomorrow
Min. : 977.1	Min. : 0.000	Min. :0.000	Min. :-0.7	Min. : 3.70	Min. :0.0000	Min. : 0.000	Min. :0.0000
1st Qu.:1010.1	1st Qu.: 1.000	1st Qu.:2.000	1st Qu.:13.1	1st Qu.:17.40	1st Qu.:0.0000	1st Qu.: 0.000	1st Qu.:0.0000
Median :1014.7	Median : 5.000	Median :5.000	Median :17.8	Median :22.40	Median :0.0000	Median : 0.000	Median :0.0000
Mean :1014.8	Mean : 4.242	Mean :4.327	Mean :18.2	Mean :22.71	Mean : 0.2209	Mean : 2.347	Mean : 0.2203
3rd Qu.:1019.4	3rd Qu.:7.000	3rd Qu.:7.000	3rd Qu.:23.3	3rd Qu.:27.90	3rd Qu.:0.0000	3rd Qu.: 0.600	3rd Qu.:0.0000
Max. :1038.9	Max. : 8.000	Max. :9.000	Max. :39.4	Max. :46.10	Max. :1.0000	Max. :367.600	Max. :1.0000


```

Luego se realizó una matriz de correlación para así poder ver cuáles variables eran

```
```{r}
#Gráfico de correlación
corplot(mcor, method = "circle", type = "lower", tl.col = "black", tl.srt = 45)
```
```



A continuación se muestran los 3 modelos realizados.

```
```{r}
#regresion lineal multiple

modelolm <- lm(RISK_MM ~ MinTemp + MaxTemp+ Rainfall + Evaporation + Sunshine + windGustDir +windDir9am + windDir3pm +windspeed9am +windspeed3pm +Humidity9am + Humidity3pm + Pressure9am +Pressure3pm +Cloud9am + Cloud3pm + Temp9am + Temp3pm + RainToday + RainTomorrow -1, data = lluvia_sin_na)

summary(modelolm)
```

```{r}
#regresion lineal multiple 2 limpio

modelolm2 <- lm(RISK_MM ~ MaxTemp+ Rainfall + Evaporation + Sunshine + windGustDir +windspeed9am + windSpeed3pm + Humidity3pm + Pressure9am + Cloud3pm+RainToday + RainTomorrow -1, data = lluvia_sin_na)

summary(modelolm2)
```

```{r}
#regresion lineal multiple 3 limpio

modelolm3 <- lm(RISK_MM ~ MaxTemp+ Rainfall + Sunshine +windspeed9am + windSpeed3pm + Humidity3pm + Pressure9am + Cloud3pm+RainToday + RainTomorrow - 1, data = lluvia_sin_na)

summary(modelolm3)
```
```

Procedimiento de Componentes Principales


```
```{r}
#-
#Analisis de componentes principales

seleccionar solo las variables numéricas
lluvia_principal <- subset(lluvia_sin_na, select = -RainTomorrow)
lluvia_PCA <- lluvia_principal[, sapply(lluvia_principal, is.numeric)]

Realizar el análisis de componentes principales
resultado_pca <- prcomp(lluvia_PCA, center = TRUE)

#Mostrar el resumen del PCA
summary(resultado_pca)
resultado_pca

plot(resultado_pca, type="l")
```



A continuación elegimos nuestros componentes principales.

```
```{r}
#tomamos el PC con una proporcion acumulada hasta el 80%
resultado_pca$rotation[,1:3]

lluvia_PCA$valPC1 <- apply(resultado_pca$rotation[,1]*t(lluvia_PCA), 2, sum)
lluvia_PCA$valPC2 <- apply(resultado_pca$rotation[,2]*t(lluvia_PCA), 2, sum)
lluvia_PCA$valPC3 <- apply(resultado_pca$rotation[,3]*t(lluvia_PCA), 2, sum)
```

Luego hacemos el modelo logístico.

```
```{r}
#modelo logistico

lluvia_PCA$RainTomorrow <- lluvia_sin_na$RainTomorrow
llueve_o_no <- glm(RainTomorrow ~ ValPC1 + ValPC2, "binomial", lluvia_PCA)
summary(llueve_o_no)

```

call:
glm(formula = RainTomorrow ~ ValPC1 + ValPC2, family = "binomial",
  data = lluvia_PCA)

coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -8.064e+00 8.399e-02 -96.01 < 2e-16 ***
ValPC1       4.800e-02 5.644e-04   85.05 < 2e-16 ***
ValPC2      -1.535e-04 4.313e-05   -3.56 0.000371 ***
---
signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 59493  on 56419  degrees of freedom
Residual deviance: 49383  on 56417  degrees of freedom
AIC: 49389

Number of Fisher Scoring iterations: 5
```

Predicciones

Análisis de Componentes Principales.

Primero separamos los datos en un conjunto de entrenamiento que abarca un 80% de los datos y uno de testeo que abarca el 20% restante.

```
```{r}
#data de logist
set.seed(1234)
indextrain2 = createDataPartition(lluvia_PCA$RainTomorrow,p=0.8,list=F)

dat2.train=lluvia_PCA[indextrain2,]
dat2.test=lluvia_PCA[-indextrain2,]

```

```{r}

pred_log <- predict(llueve_o_no, newdata = dat2.train, type = "response")
plot(pred_log)

```

```

Luego se realizó la predicción, la cual tiene un Accuracy del 81%, valor bastante alto que indica que el modelo predice de manera correcta si lloverá o no la mayoría de las veces.

```
```{r}
#Prediccion modelo logistico

predict <- ifelse(pred_log > 0.5, 1, 0)
matriz_confusion <- confusionMatrix(factor(predict), factor(dat2.train$RainTomorrow))

exactitud <- matriz_confusion$overall[["Accuracy"]]

```
```{r}
exactitud
```
```{r}
Accuracy
0.8104396
```

Finalmente se realizó una predicción con los datos que nos entrega el dataset y se obtuvo que hay un 90% de probabilidad de que no llueva “mañana”.

```
```{r}

Predictmañana <- sapply(predict, function(x) ifelse(x > 0.5, 1, 0))

conteo_predicciones <- table(Predictmañana)

porcentaje_predicciones <- conteo_predicciones / sum(conteo_predicciones) * 100
print(porcentaje_predicciones)

if (porcentaje_predicciones["0"] > porcentaje_predicciones["1"]) {
  print("Según el modelo, es más probable que mañana no lloverá.")
} else {
  print("Según el modelo, es más probable que mañana sí lloverá.")
}

```
```{r}
Predictmañana
      0      1
90.860954 9.139046
[1] "Según el modelo, es más probable que mañana no lloverá."
```

La predicción del Modelo de Regresión lineal multiple con el 20% de los datos nos da:

```
```{r}
#prediccion 20 de los datos de RLM

rmse <- sqrt(mean((prediccionestest - dat.test$RISK_MM)^2))
rmse

```
```{r}
[1] 7.018176
```